

DeepSeek到底为什么这么火爆？

如果说ChatGPT等大模型是巨型坦克，威力大，部署成本高，运行成本也高。

那么DeepSeek在威力上不输ChatGPT，部署成本低于ChatGPT，在使用成本上远低于ChatGPT。

真正的核弹是：DeepSeek蒸馏版大模型，部署成本极低，任何一个组织都可以部署蒸馏版模型，**相当于人手一个RPG火箭弹。**



ChatGPT



DeepSeek R1 671B



DeepSeek R1 distill Qwen 32/14B

原来：

成本：需要专业大规模的AI显卡，需要将近500GB的显存，约8张A100。或者4张H100 GPU。目前市面A100价格在20万。H100价格在35万。因此基础的运行成本约150万。因此大模型一般只有某些超大型公司才能够使用，难以私有化部署。

效果：国内可用的大模型效果不如ChatGPT o1,4o等模型。

VS.

现在：

成本：DeepSeek -R1蒸馏版的Qwen32B，其效果约等于ChatGpt o1，其部署成本只需要32G显存。1张A100GPU就可以运行。而且DeepSeek -R1 蒸馏版的Qwen14B 的效果与ChatGpt o1接近。性价比更高，在普通的4060的笔记本上就可以运行。

我司现有的机械革命笔记本搭载了4060的显卡，可以在本地直接运行DeepSeek-R1-Qwen14B的模型。

效果：

	AIME 2024 pass@1	AIME 2024 cons@64	MATH- 500 pass@1	GPQA Diamond pass@1	LiveCodeBench pass@1	CodeForces rating
GPT-4o-0513	9.3	13.4	74.6	49.9	32.9	759.0
Claude-3.5-Sonnet-1022	16.0	26.7	78.3	65.0	38.9	717.0
o1-mini	63.6	80.0	90.0	60.0	53.8	1820.0
QwQ-32B	44.0	60.0	90.6	54.5	41.9	1316.0
DeepSeek-R1-Distill-Qwen-1.5B	28.9	52.7	83.9	33.8	16.9	954.0
DeepSeek-R1-Distill-Qwen-7B	55.5	83.3	92.8	49.1	37.6	1189.0
DeepSeek-R1-Distill-Qwen-14B	69.7	80.0	93.9	59.1	53.1	1481.0
DeepSeek-R1-Distill-Qwen-32B	72.6	83.3	94.3	62.1	57.2	1691.0
DeepSeek-R1-Distill-Llama-8B	50.4	80.0	89.1	49.0	39.6	1205.0
DeepSeek-R1-Distill-Llama-70B	70.0	86.7	94.5	65.2	57.5	1633.0

这在以前很难私有化部署

	模型类型	私有化支持	部署环境	部署成本	中文理解	多模态支持	调用方式	适合场景
ChatGPT o1	闭源商业API	否	/	未知	英文优先	文+像+音	互联网+API	互联网/非金融/非敏感数据业务
DeepSeek R1 671B	开源模型	是	高端服务器集群	至少8张A100/H100集群	优于ChatGPT	纯文本	本地调用	金融机构/政府
DeepSeek R1 Distill QWen 32B	蒸馏版	是	服务器/高端消费级PC	2张A100, 或者NV消费级显卡	接近671B	纯文本	本地调用	金融机构/政府/内部团队
DeepSeek R1 Distill QWen 14B	轻量蒸馏版	是	消费级PC	1张消费级显卡	接近671B	纯文本	本地调用	内部团队/个人

用起来到底需要多少钱？

自己本机安装

- 基本无智能
- 简单智能
- 比较准确
- 相当准确

模型	推理GPU配置	推理硬件成本	Windows整机	MacBook
DeepSeek-R1-Distill-Qwen-1.5B	4GB	1~3万	4090显卡	MacBook M系列 32G~64G
DeepSeek-R1-Distill-Qwen-7B	8GB			
DeepSeek-R1-Distill-Qwen-14B	16GB			
DeepSeek-R1-Distill-Qwen-32B	24GB			

私有化企业内部部署成本（供多人使用）

基本无智能

简单智能

比较准确

相当准确



非常准确：
非常详细

能够联想

模型	训练显存需求	训练需求	推理显存需求	推理GPU配置	推理硬件成本
1.5B	30 GB（FP16混合精度）	单卡RTX 4090 24GB/Tesla T4 16GB	5~7 GB（FP16）	单卡1×NVIDIA RTX 4090（24GB）	2~5万
7B	140 GB（FP16混合精度）	单卡A100 80GB 或多卡A100 40GB × 2	20~25 GB（FP16）	双卡×NVIDIA RTX 4090（24GB）	50~10万
14B	280GB(FP16混合精度)	8卡A100（40G）	40~50GB(FP16)	双卡A100（40G）× 2	20~40万
32B	640GB(FP16混合精度)	8卡A100 80GB 集群（模型并行+流水线）	80~100GB(FP16)	4卡A100(40GB)*4	40~80万
70B	1.4 TB（FP16混合精度）	8卡A100 80GB 集群（模型并行+流水线）	140~200 GB（FP16）	8卡A100 80GB集群	100万+-
671B	13.42 TB（FP16混合精度）	128卡H100集群（张量/流水线并行）	1.3~2 TB（FP16）	128卡H100集群（张量/流水线并行）	---

那么大模型到底是什么？

LLM(大模型)到底是什么?



GTP大模型中的一种 那GPT到底在干什么?

根据训练出来的人类语言的特征、模式和规律 (也就是LLM大模型), 根据前面的一段话, 预测 (猜) 下一个词。这样不断的生成词, 感觉就像一个人在说话。

举个🍌

原始语料: 阿卡姆很帅! 阿卡姆很帅! 阿卡姆很帅!阿卡姆很帅!

模型:

"阿"后面的是"卡"的概率是99%

"阿卡"后面是"姆"的概率是99%

"阿卡姆"后面的是"很"的概率是99%。

"阿卡姆很" 后面是 "帅" 的概率是99%

人类输入: 阿卡姆帅么?

GPT开始预测:

阿→阿卡→阿卡姆→阿卡姆很→阿卡姆很帅


最后输出: 阿卡姆很帅!

RAG又是什么？

RAG是：检索增强生成

它结合了文档处理、搜索引擎，传统数据库查询，应用数据处理和大模型的一整套方案。可以理解成RAG把这些不同的东西像串珠子一样串起来。

作者：鲍丹



微调？ RAG？ 提示词？

成本依次下降，场景依次细化

成本/效果

微调成本最高，但是运行效率极高。相当于把数据烧制进了模型本身。运行时直接在模型中运用这些数据，知识传播的范围更广。

部署成本和运维成本居中。需要部署搜索引擎、向量数据库、RAG引擎等软件。对工程能力有要求。通过RAG可以极大增强模型使用效果。并且RAG可以共享知识库

基本没有部署成本，通过恰当的提示词设置可以达到很好的效果。但是对编写提示词的人员的业务知识，思维逻辑，使用经验有较高要求

场景

要求数据质量要求极高。适合烧制行业数据，适合用于文本、数字数据较多的行业，例如医疗、金融。

部署复杂，对数据质量有一定要求，适合企业内部，团队内部使用。

部署简单，适合细粒度场景，适合团队内部，个人使用



他们能干什么？


	硬件成本	传播效率	数据质量要求	部署难度	依赖使用者	适用场景	业务经验	格式	数据更新
微调	高	高	高	高	低	宏观	少	不固定	无
RAG	中	中	中	中	中	中等	中	有规律	准实时
提示词	低	低	低	低	高	微观	高	模板	依赖对话




	场景				
提示词	会议纪要整理	代码开发	撰写文档	代码检查	测试用例编写
RAG+提示词	投资建议	知识库	产品推荐	合规检查	审计工作
微调+RAG+提示词	行业分析	风控预警	智能客服	财报分析	

举个例子


会议纪要整理




知识库



产品推荐



大模型有哪些不足？



大模型本质上是采用**概率**去推演，具有**不确定性**。不应该直接用于精确的计算或者重要决策。

例子：大家可以算一下： $4 \times 5 - 6 \times 46 - 152 \times 47 \times 78 \times 44 \times 14 / 12$ 等于多少？

提示词和**数据质量**对大模型的结果影响巨大。

警惕大模型造成的**信息茧房**。

例子：袁世凯称帝是因为他获取的“信息”都是被编织过的，让他做出了错误的决策。



作为人类我们该怎么办？

人被AI替代？还是人使用AI？

- 重复性、低知识密度的脑力劳动会被AI替代。
- 需要根据现场环境、沟通、决策、复杂业务逻辑、精确计算的场景AI目前尚不能替代人类。
- 精通业务场景，懂得数据科学，了解AI原理的人更能驾驭AI。通过AI去奴役低知识密度的人。
- 不要高估AI的能力，也不要低估AI进化的速度。

性能/通用性	专业模型	大模型
第0级：无AI 狭义非AI：	计算器软件；编译器	广义非AI：人类参与的计算，例如亚马逊机械土耳其人
第1级：初现 初现狭义AI：GOF AI（传统AI）	简单的基于规则的系统，例如SHRDLU	ChatGPT，DeepSeek
第2级：称职 至少在熟练成人中处于第50百分位	Siri (Apple)，Watson (IBM是个医疗模型)，	尚未实现
第3级：专家 至少在熟练成人中处于第90百分位	拼写和语法检查器（Grammarly）；生成图像模型：Dall-E 2	尚未实现
第4级：大师 至少在熟练成人中处于第99百分位	象棋：Deep Blue，AlphaGo。	尚未实现
第5级：超人类 超越100%的人类	象棋：AlphaZero	

目前大模型的水平

